聚类模型

背景

1.无监督聚类旨在挖掘正常用户和欺诈用户之间的特征差异，并将不同的用户之间形成不同簇。

2.无监督聚类只能够聚成指定数量的类，但却不能够说明每一个类到底代表着什么，而我们是希望能够找出有欺诈嫌疑的客户。

3.在 2 的问题中，我们可以基于以下几种方法来做推理，首先，假设有欺诈嫌疑的人是人数最少的那个类或者几个类，并命名为欺诈类客户或欺诈类。该假设是由假设我们的项目里正常的客户要远多于不正常的客户。其次，我们可以标定一部分的欺诈用户，根据这些用户所在的簇，一方面可以检验我们的聚类效果是否达到验证要求，第二方面可以把较多标签用户所在的簇判别为欺诈用户簇。

方法

考虑到用户特征存在两种常见的数据类型：离散类别和连续数值。我们采用k-prototype算法作为base model。k-prototype算法综合了kmeans算法和kmodes算法两者来对不同的数据类型进行聚类推理。kmodes算法对于离散类别的处理也非常的简单明了，对于某一离散特征A，如果两个类别的特征相同，则两者距离为0，反之则为1。为了算法加速，kmodes算法把离散特征看作字符，并且以key-value的形式保存，也就将每个字符转换成了整型数字，在最后的输出阶段，会根据之前的key-value映射回去。

距离计算公式：

$$d(X_i, Q_l) = \sum_{i=1}^{r} (x_{ij}^r - q_{lj}^r)^2 + \gamma l \sum_{j=1}^{c} \delta(x_{ij}^c, q_{lj}^c)$$

kmeans+one hot VS k-prototype

在距离的度量方面，kmeans+onehot 和 k-prototype并不会影响样本之间的相对距离，举个例子,kmeans中 dist(A,B)>dist(B,C)，在k-prototype中一样。区别在于对于簇中心的更新，在onehot中，会对每一维度取均值，在k-prototype中会取特征中频率在高的离散变量，相当于kmeans侧重于所有值的means，而k-prototype侧重于频率值的max。

- kmeans+one hot在变量维度较高时会造成维度灾难，加剧存储空间的消耗以及计算复杂度，k-prototype可以缓解这一点，但是k-prototype在计算的同时仍要保存相关的中间变量，具体的tradeoff还是以实验为准。
- k-prototype对于离散变量的输出有实际意义，具有可解释性，虽然kmeans也可以间接做到这一点，但还是不如k-prototype直观。

输入要求

主要是针对数据的预处理，建议大部分数据预处理过程可以放在SQL端，以便于模型端的直接套用。SQL方面主要是对于离散数据的处理，按照k-prototype的算法要求，模型的输入都得是数值类型，SQL主要要把不同的离散数据转换成不同的int数值。具体的SQL参考代码后续补充。

SQL端：

- 对于缺失数据，不要以空字符填充，最好以具体数值(例如0)填充，虽然在k-modes算法中，空字符也可以被当作一个离散表征，但因为pandas不会把空字符判断成缺失字符，所以fillna等方法会失效。
- 对于维度信息，不要出现list，例如ip_info=[“中国”，“内蒙古”，“包头”]。

数据处理模块

- 处理缺失值多的特征：设定某一阈值，如果特征缺失比例超过这一阈值，考虑删除这列特征
- 处理unique特征：unique的离散特征是没有任何意义的，会直接删除这种特征
- 处理常量特征（可选）：和上者类似，例如某一列95%的数据是1，考虑删除，但针对不同特征的实际意义，由用户选择。
- 处理缺失数据用户 （可选）：某一行数据（用户）缺失数据达到一定比例，考虑删除这个用户

- 处理异常值（缺失值和inf填充）：缺失值主要是由于数据采集过程中出现的遗漏，inf是针对特征之间存在‘/’运算时可能产生的异常
- 数据规范化（RobustScalar）：数据规范化

算法输入

对于全都是数值型的输入数据，采用MiniBatchKmeans算法，对于包含离散型的数据，采用K-prototype算法

MiniBatchKmeans输入参数解析

- n_clusters：聚类中心数
- init：初始化方法，默认‘kmeans++’
- betch_size：mini batch的大小，默认100
- random_state：随机种子生成
- n_init

- verbose：算法中间输出

K-prototype算法的输入参数解析：

- n_clusters : int，可选， 默认值: 8，聚类中心个数
- **gamma：调节离散和连续数值的权重关系，默认是连续数值的标准差**
- max_iter : int，默认值: 100，算法迭代最大次数
- n_init : int，默认值: 10，算法运行（初始化）次数
- init : {'Huang', 'Cao', 'random' or a list of ndarrays}，默认值: 'Cao'，算法初始化
- n_jobs : int，默认值: 1，用于计算的job个数，用于n_init多并行计算，-1代表所有的CPU
- categorical：离散类型的index
- verbose：算法中间输出

算法指标

- Calinski-Harabasz：数值越大越好，计算类别之间的协方差和类别内部数据的协方差的比值。
- 标准差：仅针对连续性数值部分
- entropy：仅针对离散数据部分
- 规则筛选：用规则筛选出一部分标签，看标签在每个簇中的分布
- 轮廓系数：[-1,1]值越大越好，和1中的意义类似，但是计算复杂度高，不适用于大数据量场景

示例

点赞收藏场景：

和kemans相比，有着较大的召回提升，同时波动也较大，平均召回行为量翻倍，和大盘相比重合率99%，剩余1-2%的增益。

退换货场景：

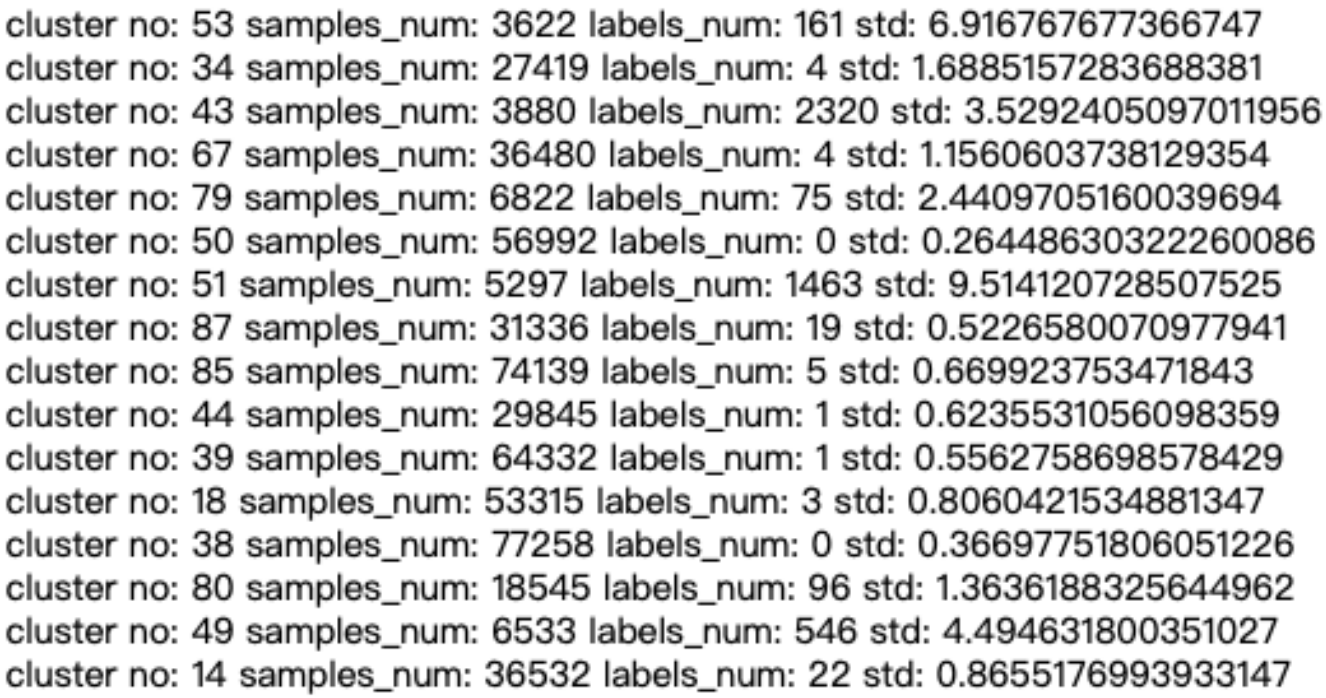

效果并不是很好，主要原因1:数据样本太多(4万/200万)聚不出太好的东西 2.数据特征没有特别构造

方案一：从拆分用户样本角度考虑，根绝某些前置条件，将200多万用户进行预划分，然后进行聚类

方案二：拓宽数据角度，不仅仅局限于退换货场景涉及到的一些用户特征